

Отчет: HF tune Transformers

Классификатор научных статей arXiv

1 Постановка задачи

Решалась задача классификации научных статей arXiv. Так как у многих статей может быть несколько категорий, я решил, что для этой задачи более естественна мультилэйбл классификация.

Так как классы крайне несбалансированы для оценки качества использовались метрики микро и макро F1.

2 Данные

Для обучения использовался этот датасет `arxiv_categories` от "Schopf Tim, Blatzheim Alexander, Machner Nektarios and Matthes Florian".

https://huggingface.co/datasets/TimSchopf/arxiv_categories

Датасет получен даунсэмплингом метаданных архива до 10%. Далее из него убраны все категории менее чем со 100 примерами в оставшихся данных.

Датасет поделен авторами на трейн-вал-тест в пропорции 80-10-10. Так я его и использовал. Из признаков использовались только заголовок и абстракт. А также категории в качестве таргета.

Split	Number of Samples
Train	163,168
Validation	20,396
Test	20,397

Таблица 1: Распределение выборок в датасете

3 Модель

В качестве модели я использовал SciBERT. Эта модель идентична по базовой структуре и числу параметров (100 млн) базовому берту, но использует словарь более подходящий для научной лексики и обучена на научной литературе. Тип модели (берт) и её размер адекватны поставленной задаче и позволяют получить хороший результат при разумных затратах вычислительных ресурсов.

Размер окна 256 токенов, поэтому на вход модели подавались конкатенированные заголовок и абстракт, обрезанные или дополненные паддингом до этого размера.

4 Обучение

Модель дообучалась на A100 с помощью библиотеки transformers батчем в 128 и использованием Vfloat16. В качестве лосса использовалась бинарная кросс энтропия. Обучение проходило на протяжении 10 эпох. В совокупности обучение заняло 150 минут.

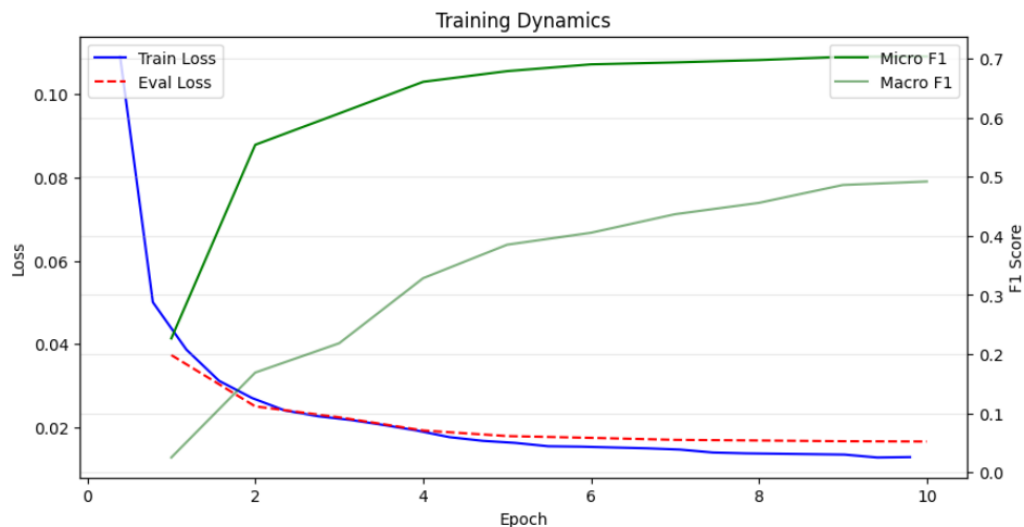


Рис. 1: Динамика изменения Loss и F1-score в процессе обучения

Модель достаточно быстро (за 4 эпохи) вышла на достойные 0,65 Micro-F1, при существенно более низком Macro F1 = 0,30. Таким образом модель быстро освоила частые классы. Следующие эпохи модель доучивала эти классы и Macro F1 уверенно продолжал расти и дошел до 0,50, хотя валидационный лосс на последних эпохах уже почти не менялся.

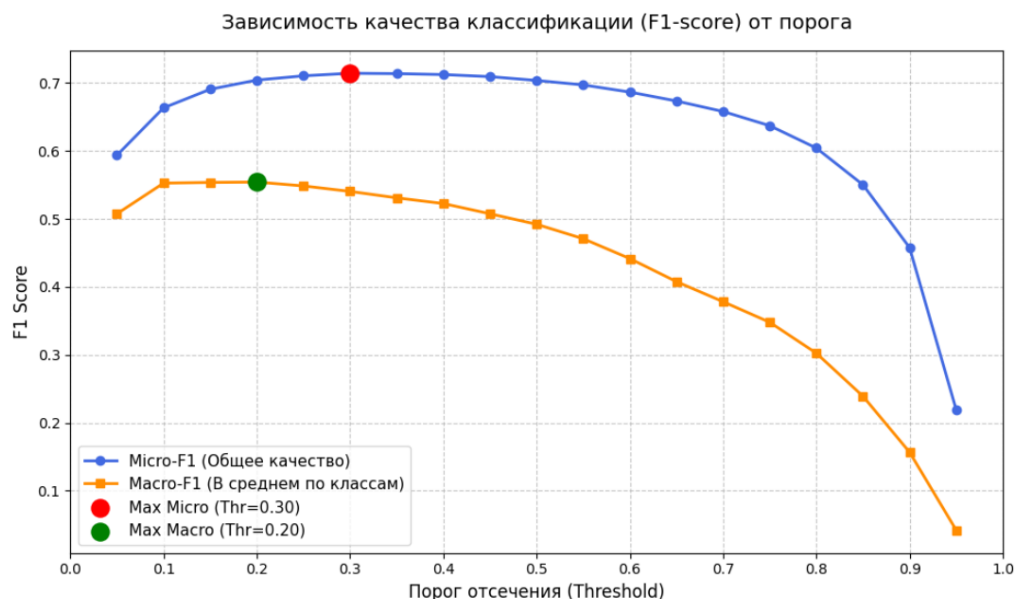


Рис. 2: Подбор порога

После обучения я проверил метрику при разных уровнях порогов. Просто снижением порога со стандартного 0,5 до 0,25 удалось увеличить метрики макро с 0,70 до 0,71 и микро с 0,50 до 0,55. Бесплатный перфоманс. Найс

5 Развертывание

Демо модели развернуто на Hugging Face Spaces

Ссылка: <https://huggingface.co/spaces/artem-volosatov/arxiv-classifier>

Для фронтенда использовался Streamlit. В демо реализована форма для ввода заголовка и аннотации (заголовок является обязательным полем). После запуска выводятся все категории выше порога в 0.25.

Для удобства демонстрации я добавил 5 кнопок с уже заполненными примерами из разных областей. Все примеры из свежих статей, которых не было в датасете и имеют на архиве хотя бы две категории.